

CSE5026: Introduction and Frontiers of Cognitive Science

Auditory System and Speech

Yang Xu 徐炆

Department of Computer Science and Engineering
Southern University of Science and Technology

Overview

- Auditory Sensory System 听觉系统
- Auditory Pathways 听觉神经通路
- Speech Perception 语音感知
- Speech Production 语音生成


Auditory Perception 听觉感知

- 声波作用于听觉器官，使其感受细胞兴奋并引起听神经的冲动发放传入信息，经各级听觉中枢分析后产生听觉。
- 听觉过程包括 **机械 → 电 → 化学 → 神经冲动 → 中枢信息加工** 等环节。
 - 1. 从外耳的集声至内耳基底膜的运动是**机械**运动，
 - 2. 毛细胞受刺激后引起**电**变化，**化学**介质的释放、**神经**冲动的产生等活动，
 - 3. 冲动传至中枢后则是一连串复杂的**信息处理**过程。


听觉形成的过程

Source: https://en.wikipedia.org/wiki/Auditory_system

- 声音 => 外耳 => 中耳 => 耳蜗听觉感受器 => 听觉神经 =>
- 脑内听觉传导通路 => 听觉皮层 (在此形成听觉)
- External auditory canal: 外耳道 (2.5~3.5 cm)
- Tympanic membrane: 鼓膜 (8~10 mm²)
- Cochlea 耳蜗
- 听觉神经: vestibular nerve 前庭神经;
cochlear nerve 耳蜗神经



听觉形成的过程



Malleus: 锤骨

Incus: 砧骨

Stapes:


Cochlea (耳蜗): Filled with liquid and the sound vibrations make the fluid ripple (产生涟漪)

Stereocilia: 静纤毛

Hair cell: 毛细胞


人类听觉的频率范围

- 人类: 20 ~ 20,000 Hz
- 狗/猫: 下限与人类无差, 上限更高 (~65,000 Hz)
- 蝙蝠: 上限约在 200 kHz
- 白鲸: 1k~123k Hz
- 宽吻海豚: 150 ~ 150k Hz



Source: https://en.wikipedia.org/wiki/Hearing_range

强度-频率 (intensity-frequency) 范围



测量声音强度的指标:

客观:

- 声强 (intensity)
- 声压级 (sound pressure level)

≠

主观: 声音的响度 (loudness)


声压级 Sound Pressure Level

- SPL: 声音的有效压力相对于参考值的对数值

$$L_p = \ln\left(\frac{p}{p_0}\right) \text{ Np} = 2 \log_{10}\left(\frac{p}{p_0}\right) \text{ B} = 20 \log_{10}\left(\frac{p}{p_0}\right) \text{ dB}$$

- 空气中的常用参考声压 $p_0 = 20\mu\text{ Pa}$
通常认为它是人类听觉的强度阈值
(约相当于3米外蚊子飞行时发出的声音)

Source: https://en.wikipedia.org/wiki/Sound_pressure



常见声压级 SPL 例子

声源	距离	Pa	dB
喷气发动机	1米	632	150
人类最响亮的声音	1英寸	110	135
疼痛阈值	紧贴耳朵	20–100	120–134
小号	0.5米	63.2	130
婴儿哭声	-	-	80-130
正常对话	1米	2×10^{-3} –0.02	40–60
非常安静的房间		2.00×10^{-4} ... 6.32×10^{-4}	20-30

复习：韦伯定律

- 绝对阈限 absolute threshold: 个体对单一刺激引起感觉时，所需最低的刺激强度。
- 差别阈限 differential threshold: 个体所能觉察的刺激物的最小差异量
- Weber's law 又称“感觉阈限定律”：在一定范围内，差别阈限近似为刺激强度的恒定的分数：

$$\frac{\Delta I}{I} = k$$

ΔI : 差别阈限; I : 最初刺激强度
 k 为常数 (韦伯分数)

Weber's Law 韦伯定律

- 常见韦伯分数 k
括号内为初始刺激强度

$$\frac{\Delta I}{I} = k$$

ΔI : 差别阈限; I : 最初刺激强度
 k 为常数 (韦伯分数)


刺激类型	韦伯分数
音高 (2000 赫兹)	1/333
深压 (400 克重)	1/77
视觉明度 (1000 光子)	1/62
举重 (300 克重)	1/53
响度 (100 分贝; 1000 赫兹)	1/11
橡胶气味 (200 嗅单位)	1/10
皮肤压力 (5 克重 / 每平方毫米)	1/7
咸味 (3 克分子 / 每公斤)	1/5

主观响度 Loudness

- 响度 Loudness: 对声压的主观感受, 可以使用听力计来测量 (耳平衡法)。
- 人耳对响度的灵敏度随频率变化, 可绘制等响度图 (Equal-loudness contours)




Source: <https://en.wikipedia.org/wiki/Loudness>



Auditory Cortex 听觉皮层

- 听觉皮层在大脑的颞叶 (temporal lobe)
- 可被细分为 初级 (A1)、次级 (A2), 以及其它关联区等区域。
- 听觉皮层对从耳蜗传入的信息进行时间和频率的分析。
- 听觉皮层中的神经元根据其最佳响应的声音频率进行组织：一端的神经元对低频响应最佳, 另一端的对高频响应最佳。
- 功能区分: A1 能够编码听觉刺激的复杂抽象信息, 而不会编码其“原始”信息, 例如特定的频率内容。




Overview

- Auditory Sensory System 听觉系统
- Auditory Pathways 听觉神经通路
- **Speech Perception 语音感知**
- Speech Production 语音生成

Ellis and Young 口语通路模型

- The Ellis and Young (1988) Transcoding Model for Speech Perception and Production.




Source: <https://www.smithsrisca.co.uk/PSYellisyoung1988.html>

口语通路模型

- 模型包含5个成分：
 - 听觉分析系统**：用于从声波中提取 **音素 (phoneme)** 和其它声音信息。
 - 音素/音位 phoneme: 语言中能够区别词之间意义的最小语音单位
 - 例：汉语普通话


塞音（不送气）	/b/	爸 (bà)、波 (bō)
塞音（送气）	/p/	怕 (pà)、坡 (pō)



Source: <https://zh.wikipedia.org/zh-cn/音位 - 实例>

口语通路模型


- **听觉输入词典：**
包含听者知道的关于口语单词的信息，但不包含语义信息。(Auditory input lexicon)
- 目的是通过恰当地激活词汇单元来识别熟悉的单词。



口语通路模型


- **语义系统：**
单词的词义 (word senses) 储存于语义系统。

- Critic: this is an abstract concept or module, whose implementation could be distributed (like semantic embeddings).




口语通路模型

- **言语输出词典：**
提供单词的口语形式。
(Speech output lexicon)




口语通路模型

- **音素反应缓冲器：**
负责提供可分辨的口语声音。




口语通路模型

- 从**听到**一个单词到**说出**它的过程之间存在三条通路
- **通路1**：代表了无脑损伤的正常人群识别和理解熟悉单词的认知通路。



口语通路模型


- **通路2**：如果患者能够使用通路2，但通路1和3受到严重损伤，那么他们应该能够重复 (复述) 熟悉的单词，但不能理解这些单词的意义。



口语通路模型

Source: <https://www.smithsrisca.co.uk/PSYellisyoung1988.html>


- **通路3**：如果患者的通路2受损，将导致词义性耳聋 (word meaning deafness)，表现为难以理解听到的语言，但是可以重复和说出完整的单词。



扩大的通路模型

Source: <https://www.smithsrisca.co.uk/PSYellisyoung1988.html>

- The complete Ellis & Young (1988) model describes the flow of information during both spoken and written language.
- 将视觉语言 (written) 与口语区分描述。
- 语义系统为核心的共享组件。



Overview

- Auditory Sensory System 听觉系统
- Auditory Pathways 听觉神经通路
- Speech Perception 语音感知
- **Speech Production 语音生成**

Articulatory Phonetics 发音语音学

- 研究当口腔、喉咙和鼻子中的各种器官对来自肺部的气流进行调节时，不同的音素是如何产生的。
- 发声器官 vocal organs
 - Vocal fold (cord): 声带
 - 如果声带靠得很近（没有完全闭合），当空气从中通过时就会振动；如果离得很远，就不会振动。
 - 声带振动时发出的声音称为浊音 (voiced).
E.g., [b], [d], [g]
 - 声带不振动发出的声音为清音 (unvoiced).
E.g., [p], [t], [k]






Figure 14.4 The vocal organs, shown in side view. (Figure from OpenStax University Physics, CC BY 4.0)

辅音 (consonants) 与元音 (vowels)

- 语音可分为两大类：**辅音与元音**。
- 辅音 (consonants) 是通过某种方式限制或阻塞气流形成的，并且可以是浊音或清音。
- 元音 (vowels) 的阻碍较小，通常是浊音，而且一般比辅音更响亮、持续时间更长。
- 可以根据发音部位 (place of articulation) 对辅音/元音进一步归类



英语辅音的主要发音部位



不同元音对应的舌的位置

Syllables 音节

- 辅音和元音结合构成一个**音节** syllables。
- 音节是一个类元音（或响音）以及与其联系最紧密的一些周边辅音组合而成的声音。
 - 例：“dog”有一个音节 [d aa g]; “catnip”这个词有两个音节，分别是 [k ae t] 和 [n ih p]
- 音节核心的元音称为核音 (nucleus)。
- 开头的辅音称为首音 (onset)。
- 跟在核心音后面的辅音或辅音序列称为尾音 (coda)
- 韵 (rime) = nucleus + coda




Figure 14.8 Syllable structure of *ham*, *green*, *eggs*. σ =syllable.

Prosody 韵律学

- 韵律学是对语言的语调 (intonational) 及节奏 (rhythmic) 方面的研究, 尤其关注**基频 (F0)**、**能量 (energy)** 和时长 (duration) 在传递语用 (pragmatic)、情感或会话互动意义上的运用。
- 简而言之, 能量 => 声音的响度, 基频 (F0) => 声音的频率。
- 韵律可用于标记语篇结构, 例如陈述句和疑问句之间的区别。
- 韵律突显的三个维度: accent 重音, lexical stress 词汇重音, schwa 弱化元音/央元音。

韵律突显 Prosodic Prominence


- **重音 accent**: 具有突显特征的词或音节带有音高上的重音 (pitch accent).
 - 例, 带下划线为重音词:

(14.1) I'm a little surprised to hear it characterized as happy.
- **词汇重音 lexical stress**: 并非单词的每个音节都能重读, 音高重音必须在具有词汇重音的音节上体现出来。
 - 例, 下划线为重音词, 其中带有重音的音节 (发音更响、更长的音节) 加粗:


(14.2) I'm a little sur**prised** to hear it characterized as happy.
 - 词汇重音在词典中规定。
- 非重读音节的元音进一步弱化, 成为弱化元音/央元音 (schwa)。

韵律特征：语调 Tune

- 两个具有相同重音的语句，仍可能因语调 (tune) 不同而在韵律上存在差异。
- 语调是值其 **基频 (F0)** 随时间的升降变化。
 - 例：陈述句与“是非”问题的区别



Final F0 raise to indicate a yes-no question
(question raise)



Final F0 drop to indicate a declarative intonation
(final fall)

语音信号处理基础

- 声波的主要特征由频率 (frequency) 和幅度 (amplitude) 决定。
- $y = A * \sin(2\pi ft)$, 幅度为 A , 频率为 f 的正弦波




Figure 14.10 A sine wave with a frequency of 10 Hz and an amplitude of 1.

$$f = 10\text{Hz} \Rightarrow 10 \text{ cycles per sec}$$

语音声波

- 通过绘制空气压力 (air pressure) 随时间的变化来表示声波。




Figure 14.11 A waveform of the vowel [iy] from an utterance shown later in Fig. 14.15 on page 15. The y-axis shows the level of air pressure above and below normal atmospheric pressure. The x-axis shows time.

Positive y : the amount of **compression**; negative y : **rarefaction** (uncompression)

语音声波 => 语音信号

- 模拟-数字转换 analog-to-digital conversion。主要步骤：**采样与量化**。
- 采样率 sampling rate：每秒采集的声音样本数量 f_s 。能够准确测量的信号频率，需满足其最大频率在采样率的 1/2 以下，称为 Nyquist 频率 $f_N = \frac{1}{2} f_s$
- 人类语音中的大多数信息都位于 ≤ 10000 Hz 以下的频率中，因此要达到完全的准确性，采样率 $f_s = 20000$ Hz 是必要的。
- 早期座机电话采样率：8 kHz。现代网络视频的常见音频采样率：48 kHz。

语音声波 => 语音信号


- 即使是 8 kHz 的采样率，每秒语音也需要8000次振幅测量，因此高效存储振幅测量数据十分重要。
- **量化 (quantization)**：将振幅存储为整数，8 位 (值域 -128 ~ 127) 或 16 位 (-32768~32767)。
 - 早期电话: 8 kHz 采样 + 8-bit 量化
- **μ -law PCM** (pulse code modulation) 脉冲编码调制：

$$F(x) = \frac{\text{sgn}(x) \log(1 + \mu|x|)}{\log(1 + \mu)} \quad -1 \leq x \leq 1 \quad (\mu=255 \text{ for 8 bits})$$

- 使用对数压缩的原理：人类的听觉在小强度下比在大强度下更敏感。


语音信号的频率与振幅

- 语音信号虽非正弦曲线，但仍表现出周期性：



- 在 38.75 ms 内出现了10次形状相似的波峰 $\Rightarrow T = \frac{10}{0.03875} \approx 258 \text{ Hz}$
- 人声是由声带的规律性开合引起的: 当声带张开时, 空气从肺部向上推送, 形成一个高压区域。当声带闭合时, 就没有来自肺部的压力了。
- 波形图上每个主要**波峰**对应着声带的一次张开, 声带振动的频率称为波形的**基频**, 通常缩写为 **F0**。

语音信号的频率与振幅



通常可以在可以在音高
轨迹(pitch track) 中绘制
随时间变化的基频 F0 大
小。

注：这里是指 F0 的频率值
(图中区间 0 - 500 Hz)，而非
基频对应的振幅。

对问句 “Three o’clock?”, 基频F0 在结尾处上升。

语音信号的频率与振幅

- 除了某一时刻的振幅值外，通常还需要知道在某段时间范围内的平均振幅。
- 信号的功率 power 定义为振幅的平方和：

$$\text{Power} = \frac{1}{N} \sum_{i=1}^N x_i^2$$

- 更常用的是声音强度 intensity，将功率标准化到人类听觉阈值，其测量单位为分贝（dB）。

$$\text{Intensity} = 10 \log_{10} \frac{1}{NP_0} \sum_{i=1}^N x_i^2$$

P_0 为听觉阈值压力 $= 2 \times 10^{-5} \text{Pa}$

语音的音高和响度

- 语音的**音调/音高 (pitch)** 与频率有关，**响度 (loudness)** 与强度有关。
- 音高 (pitch) 是 基频F0 所产生的心理感觉，或者说是基频的感知对应物。
 - 一般来说，声音的基频更高，我们会感觉它的音调更高。
 - 这种关系并非线性，因为人类听觉对不同频率的敏感度不同。
 - 人类的音高感知在100 ~ 1000 Hz 之间最准确，此时音高与频率呈线性相关。
 - 对 1000 Hz 以上的频率感知不太准确，此时音高与频率呈对数关系。

- **Mel scale 模型：**

$$m = 1127 \ln\left(1 + \frac{f}{700}\right)$$

在听觉上音高距离相等的成对声音，它们之间的mel数值也相等。

语音波形的解读

Source: <https://web.stanford.edu/~jurafsky/slp3/14.pdf>

- 元音较容易识别：元音的特点是时长较长，且相对响亮。
 - 图中六个元音，[iy], [ax], [ae], [ax], [ey], [iy]，都有规律的振幅峰值，表明它们是浊音。
- 对于塞辅音，通常能看到一段接近静音的时期，随后是幅度轻微的爆发。
 - Two [b]'s in baby

