

CSE5026: Introduction and Frontiers of Cognitive Science

Learning

Yang Xu 徐炆

Department of Computer Science and Engineering
Southern University of Science and Technology

Overview

- Introduction
- Human Learning Theories
- Reinforcement Learning

学习 Learning

- 学习能力是人类智能的根本特征。
 - 人从出生开始就不断地向环境学习。
 - 人的认识能力和智慧才能是在毕生的学习中 (life-long learning) 逐步形成、发展和完善。
- Herber A. Simon (司马贺): “Learning is any change in a system that produces a more or less permanent change in its capacity for adapting to its environment.” (“系统为了**适应环境**而产生的某种长远变化，这种变化使得系统能够更有成效地在下一次完成同一或同类的工作。”)

人类学习理论 Human Learning Theories

- 有关学习的实质 (nature)、过程 (process)、规律 (principles) 以及制约学习的各种条件的理论探讨和解释。
- **行为主义**理论 Behaviorism
- 认知学习理论 Cognitivism
- 人本主义理论 Humanism

行为主义 Behaviorism

- 经典行为主义
- 华生 John B. Watson, 1878-1958 
 - 《行为主义者心目中的心理学》 (Psychology as the Behaviorist Views It)
- 行为是个体对环境刺激所做出的反应。他们把环境看成是刺激，把伴而随之的有机体行为看作是反应，认为所有行为都是习得的。
- 环境决定论 (包含后人对华生的过度解读)
 - 有什么样的刺激，必定会产生什么样的反应。否定遗传的作用。过分夸大环境和教育的作用。

经典行为主义

- 刺激-反应模型 Stimulus - Response (S-R)
- 十二个婴儿：
 - “给我十二个健康、发育良好的婴儿，以及我指定的抚养环境，我保证可以随机挑选一个，把他培养成我指定的任何类型的专家——医生、律师、艺术家、商贾，甚至乞丐和小偷，无论他天生的天赋、爱好、倾向、能力、职业，以及祖先的种族如何。我承认我的说法有些夸张，但那些持相反观点的人也同样如此，……”

Source: <https://zh.wikipedia.org/zh-cn/小艾伯特实验>

Watson's Little Albert Experiment

- Albert: An 11 month old infant

- ① 巨响（非条件刺激）出现，引起恐惧（无条件反射）。
- ② 白鼠（中性刺激）与巨响（非条件刺激）同时出现，引起恐惧（无条件反射）。
- ③ 白鼠（条件刺激）出现，引起恐惧（条件反射）。学习在此时发生。




新行为主义



- 斯金纳 B.F. Skinner, 1904-1990
- 主要贡献：完善了操作条件反射 (operant conditioning) 和效果律 (law of effect) 的概念。
- 系统地探索间歇性强化程序、通过逐步逼近塑造新行为、通过二级（习得的）强化物将复杂的行为序列串联起来，以及“迷信的”（偶然强化的）行为。
 - **发明**：训练老鼠按压杠杆和鸽子啄键行为的“斯金纳箱”。
 - 二战时期的导弹制导系统（从未投入使用），该系统利用导弹透明鼻锥内一只训练有素的鸽子持续啄击目标。
 - “空气婴儿床”：把他的幼女放在一个温控玻璃箱里玩耍。（导致斯金纳“拿女儿做实验”的都市传说，导致她长大后不适应社会——系不实流传）

斯金纳箱: 小白鼠实验1

- 箱壁的一边有一个可供按压的杠杆，在杠杆旁边有一个承受食物的小盒紧靠着箱壁上的小孔，小孔外是食物释放器。
- 动物在箱内按一下杠杆，即有一粒食物从小孔口落入小盒内。
 - 一只白鼠禁食24小时后被放入箱内，开始它在箱内探索，偶尔按压了杠杆，获得食丸。
 - 白鼠开始可能并没有注意到食物落下，但若干次重复后，就形成了压杆取食的条件反射。



斯金纳箱：小白鼠实验2

- 将一只小白鼠放入一个有按钮的箱中。每次小白鼠不按下按钮，则箱子**通电**。
- 结果：小白鼠学会了按按钮。
 - ——但是一旦箱子不再通电，按按钮的行为迅速消失。
- 惩罚可以迅速建立行为模式，但是惩罚具有一定副作用：惩罚建立起来的行为模式容易迅速消失。

斯金纳箱：小白鼠实验3

- **固定时间奖励**：将一只很饿的小白鼠放入箱中，由一开始的一直掉落食物，逐渐降低到每1分钟后，按下按钮可概率掉落食物。
- 结果：小白鼠一开始不停按钮。过一段时间之后，小白鼠学会了间隔1分钟按一次按钮。
- 当掉落食物停止时，小白鼠的行为消失。
 - 因为行为者知道短期内行为不会再得到奖励。

斯金纳箱：小白鼠实验4

- 概率型奖励：将一只很饿的小白鼠放入箱中，多次按下按钮，有概率掉落食物。
- 结果：**小白鼠学会了不停按钮。**
- 且当不再掉落食物时，小白鼠的学习行为消失速度非常慢。
 - 随着概率越来越低，小白鼠按按钮的行为没有变化，直至40-60次按钮掉落一个食物，小白鼠仍会不停按。
 - 同样适用于斯金纳的鸽子 (每秒能做出2-3次反应，连续反应长达15小时)

斯金纳箱：小白鼠实验4

- 这组实验模拟了为什么赌博会给予人依赖感——**成瘾性**。
- 由于概率性地给与奖励，行为者很难直接判断**奖励机制**是否失效。
- 所以单次的失败不会给予明显的“惩罚”——无法终止行为者的习惯，从而学习行为会一直持续下去。

斯金纳箱：小白鼠实验5

- **“迷信”的小鼠**：在掉落食物前，小白鼠正好在进行某些偶然的行为——比如撞箱子、作揖、转圈跳舞——小白鼠就会不断重复这些行为，培养成奇特的习惯。
- 许多游戏中的谣言，如“在中午抽奖容易中大奖”、“带满一背包的幸运兔脚可以获得更好的装备”，原理与之相同。

斯金纳箱推广到人类学习

- 人类学习行为的性质虽然比动物复杂得多，但也要通过操作条件反射 (operant conditioning) 来习得。
- 操作条件反射的特点：奖励 (强化刺激) 必须跟随在**反应之后**发生，不是与反应同时，也不是先于反应发生。
- 学习的本质不是奖励的替代，而是反应的改变。

其它人类学习理论


- **认知主义**：该理论侧重于内部心理过程 (mental process)，如记忆、感知和解决问题 (problem solving)。
 - 核心概念：学习涉及信息处理、构建称为图式 (schemas) 的心理结构，以及在新知识和现有知识之间建立联系。
- **人文主义**：该理论强调个体的个人成长、自由意志，以及动机和自我实现 (self-fulfillment) 的重要性。
 - 核心概念：当学习与个人的需求和目标相关，且个人具有自我驱动力时，学习效果最佳。

Overview

- Introduction
- Human Learning Theories
- **Reinforcement Learning**

强化学习 Reinforcement Learning

- 代理人/智能体 agent
- 与环境 (environment) 产生一系列的交互，学习合适的策略以最大化它从环境得到的奖励 (reward)



在第 t 步交互时刻:

- 根据当前环境状态 $s_t \in \mathcal{S}$, 采取行动 $a_t \in \mathcal{A}(s_t)$
- 环境给出奖励 r_t
- 状态更新到 s_{t+1}

强化学习 RL


- 基础学习目标：在所有可能的行动轨迹上 $\tau = \{a_1, a_2, \dots, a_T\}$ ，最大化累积的总奖励 $R(\tau) = \sum_{t=1}^T r_t$ 。
- 策略模型 (policy model) θ : 给出每条行动轨迹 τ 的概率 $P_\theta(\tau)$ 。
- 轨迹 τ 对应的奖励: $R(\tau)$ 。
- 目标函数 (通用形式):

$$\mathcal{J}(\theta) = \arg \max_{\theta} \mathbb{E}_{\tau \sim P_\theta} [R(\tau)] = \arg \max_{\theta} \sum_{\tau} R(\tau) P_\theta(\tau)$$

Source: https://docs.pytorch.org/tutorials/intermediate/reinforcement_q_learning.html

Deep Q Learning (DQN)

- CartPole-v1 倒立摆任务: 智能体需要在向左或向右移动小车之间做出选择, 以保持连接小车的杆子的直立。



行动空间 $\mathcal{A}(s_t) = \{left, right\}$

奖励函数 $Q^*: State \times Action \rightarrow \mathbb{R}$

当前状态下的策略模型:

$$\pi^*(s) = \arg \max_a Q^*(s, a)$$

Source: https://docs.pytorch.org/tutorials/intermediate/reinforcement_q_learning.html

Deep Q Learning (DQN)

- 奖励函数 Q^* 是未知的，可以通过神经网络来学习。
- 训练策略模型以最大化折扣累积奖励 (discounted cumulative reward) $R_{t_0} = \sum_{t=t_0}^{\infty} \gamma^{t-t_0} r_t$, 也称回报。
 - 折扣系数 $\gamma \in [0,1]$, 确保 R_{t_0} 是收敛的。
 - 较低的 γ 值：来自遥远未来的奖励不如近期奖励重要。
 - 鼓励智能体收集在时间上更接近的奖励，而非那些在未来时间上相距较远的同等奖励。

Deep Q Learning (DQN)

- 对 Q 的更新需要满足 Bellman 等式:

$$Q^\pi(s, a) = r + \gamma Q^\pi(s', \pi(s'))$$

最终目标是学习到稳定的
奖励函数 Q^* 和策略模型
 $\pi^*(s) = \arg \max_a Q^*(s, a)$

- 等式两边的差值被称为时间差分误差 δ :

$$\delta = Q(s, a) - \left(r + \gamma \max_a Q(s', a) \right)$$

- 此误差通过 Huber loss 的形式来最小化:

$$\mathcal{L}(\delta) = \begin{cases} \frac{1}{2} \delta^2 & \text{for } |\delta| \leq 1, \\ |\delta| - \frac{1}{2} & \text{otherwise.} \end{cases}$$

使学习更稳定

RL in LLMs

- Action a_t : Generates a token at position t
- State s_t : User's input + current generations ($< t$)
- Trajectory $\tau = \{a_1, a_2, \dots, a_T\}$: the complete generation of length T
 - Term in LM: trajectory probability $P_\theta(\tau) = \prod_t P(a_t|s_t)$
 - Equivalent to term in RL: $\pi_\theta(a_t|s_t)$ 
- Reward $R(\tau)$: A score on the generation τ obtained from
 - The labelers
 - or, a learned reward model
- LLM needs to tune its parameter θ in order to maximize the reward without ruining the language modeling performance